

클래식 스탯 vs 세이버메트릭스

무엇이 팀 성적을 더 잘 설명하는가?

MLB 4개 시즌(2021-2024) 120개 팀-시즌 데이터를 활용한 상관 분석

1. 문제 정의

야구에서 선수와 팀을 평가할 때 오랫동안 타율(BA)·안타(H) 같은 전통적인 '클래식 스탯'이 기준이 되어 왔다. 그러나 최근에는 OPS, OPS+ 같은 세이버메트릭스 지표가 선수의 실제 기여를 더 정확히 측정한다고 평가받는다.

그렇다면 실제 데이터에서도 세이버 지표가 팀의 득점(성적)을 더 잘 설명할까? 이 질문을 직접 검증해 보고자 했다.

- 타겟 지표: 팀 득점(R) — 공격 생산성의 최종 결과물
- 클래식 지표: 타율(BA), 안타(H), 홈런(HR)
- 세이버 지표: OPS, OPS+

2. 데이터 수집 및 전처리

- 출처: MLB 공개 팀 시즌 타격 기록
- 범위: 2021-2024시즌, 30개 구단 → 총 120개 팀-시즌
- 표본 설계: 한 시즌(30팀)만으로는 상관분석의 신뢰도가 낮아 4개 시즌을 결합해 표본을 확대. 코로나로 경기 수가 절반이었던 2020시즌은 데이터 일관성을 위해 제외했다.

데이터의 양뿐 아니라 품질을 의심하고 걸러내는 것이 분석의 출발점이라 보았다.

3. 분석 방법



각 지표가 팀 득점(R)과 갖는 피어슨 상관계수를 계산했다. 상관계수가 높을수록 "팀 성적을 잘 설명하는 지표"로 해석할 수 있다. 클래식 그룹과 세이버 그룹의 평균 상관을 비교해 어느 진영이 더 높은 설명력을 갖는지 확인했다.

4. 결과

지표	분류	득점과의 상관
OPS	세이버	0.954
OPS+	세이버	0.866
HR	클래식	0.802
H	클래식	0.768
BA	클래식	0.687

- 세이버 지표 평균 상관: 0.910

• 클래식 지표 평균 상관: 0.752



5. 핵심 인사이트

1) 세이버메트릭스 지표가 팀 득점을 더 잘 설명한다. OPS(0.954)는 거의 완벽에 가까운 상관을 보였고, 세이버 그룹 평균이 클래식을 0.16이나 앞섰다.

2) 가장 전통적인 지표인 '타율'이 설명력은 가장 낮았다. 타율(BA, 0.687)은 야구에서 가장 오래 떠받들어진 지표지만, 정작 팀 득점 설명력은 5개 지표 중 꼴찌였다. 타율은 '안타를 쳤는가'만 볼 뿐 **출루와 장타(=득점으로 이어지는 가치)를 담지 못하기 때문**으로 해석된다. OPS는 이 둘을 모두 반영해 득점과 강하게 연결된다.

표면적으로 익숙한 지표가 반드시 본질을 설명하는 것은 아니다. 데이터 분석의 핵심은 '눈에 익은 숫자'가 아니라 '결과를 설명하는 숫자'를 찾아내는 데 있다.

6. 데이터팀 활동과의 연결

이 프로젝트에서 사용한 사고 과정은 BDAI 데이터팀의 실제 업무와 동일하다고 생각한다.

- **표면 지표 vs 본질 지표 구분** → LMS 데이터에서도 '페이지 체류 시간' 같은 표면 지표가 아니라 '과제 제출·완주' 같은 본질적 참여 지표를 찾아내는 데 적용할 수 있다.
- **표본 품질 검증(2020 제외)** → 학회원 데이터 분석에서도 이상치·예외 기수를 걸러내는 판단으로 이어진다.
- **상관 기반 원인 탐색** → "어떤 행동이 학회원의 완주로 이어지는가"를 데이터로 밝히는 분석에 그대로 쓰인다.

겉으로 드러나는 숫자 너머의 **진짜 원인을 데이터로 짚어내는 분석**을 데이터팀에서 이어가고 싶다.

분석 도구: Python (pandas, matplotlib, seaborn) · 분석 기법: 상관분석